

# **Parsificazione**

**I**

**(analisi top-down)**

# Analisi sintattica I

Data una grammatica  $G$  l'analizzatore sintattico o parsificatore legge la stringa sorgente e se appartiene al linguaggio  $L(G)$  ne produce una derivazione o un albero sintattico, altrimenti si ferma segnalando l'errore.

## Due classi importanti di analizzatori

Discendenti o top-down

Ascendenti o bottom-up

Come per l'analisi lessicale, anche per l'analisi sintattica sono stati sviluppati strumenti per la generazione automatica di parsificatori, sia per l'analisi bottom-up (Yacc) sia per quella top-down (Antlr).

# Analisi sintattica deterministica

Un analizzatore sintattico *deterministico* leggendo 1 (o più) caratteri in input può *eliminare le ambiguità* e scegliere sempre la strada giusta che porta al riconoscimento della stringa. Ovviamente il modello su cui si rifanno tutti gli analizzatori sintattici (più o meno fedelmente) è l'automa a pila.

Le grammatiche che permettono **parsing predittivo discendente** sono chiamate **LL(k)**, quelle che permettono **parsing predittivo ascendente** sono chiamate **LR(k)**, dove  $k$  è il numero di simboli necessari per individuare la produzione senza ambiguità.

La famiglia **LL(k)** contiene tutti e soli i linguaggi che possono essere definiti da una grammatica LL(k) per un valore finito di  $k \geq 1$ . Non tutti i linguaggi che hanno riconoscitori deterministici sono generabili da grammatiche LL(k), cioè la famiglia dei linguaggi LL(k) è strettamente contenuta nella famiglia dei linguaggi che hanno riconoscitori deterministici.

# Parser LL(1) (iterative)

Un parser LL(1) iterativo per una grammatica LL(1) (definita esattamente in seguito) è costituito da:

- la *stringa in input* cui viene aggiunto un mark di fine stringa che denotiamo con \$. L'input viene letto sequenzialmente come negli automi.
- una *pila* i cui elementi possono essere *terminali* o *non terminali* della grammatica

Durante l'analisi input e pila vengono modificati *esattamente* come l'input e la pila rappresentati nelle configurazioni istantanee di un *automa a pila* (*non deterministico*) che riconosce la grammatica G costruita nel modo standard.

Ma nell'algoritmo di parsificazione LL(1) la *decisione* su come espandere i nonterminali in cima alla pila viene presa in modo deterministico *guardando il primo simbolo dell'input (lookahead)*.

Quando invece in cima alla pila si trova un terminale basterà verificare la corrispondenza di questo col simbolo in input e avanzare la testina di lettura (come nell'automa a pila).

# Parsing LL(1) (top-down o discendente)

Consideriamo per esempio la seguente grammatica (LL(1)).  
Notare l'uso di "\$" per definire la fine stringa:

Grammatica

- 1  $S \rightarrow ( S )$
- 2  $S \rightarrow [ S ]$
- 3  $S \rightarrow < S >$
- 4  $S \rightarrow \varepsilon$

Stringa in input: [ < > ] \$

La decisione su come espandere S  
viene presa in funzione dei simboli  
in rosso, primi simboli dell'input

accettazione

Input

pila

[ < > ] \$

[ < > ] \$

< > ] \$

< > ] \$

> ] \$

> ] \$

] \$

\$

			S
--	--	--	---

	[	S	]
--	---	---	---

		S	]
--	--	---	---

<	S	>	]
---	---	---	---

	S	>	]
--	---	---	---

		>	]
--	--	---	---

			]
--	--	--	---

--	--	--	--



# FIRST

Data una grammatica  $G = \langle V, \Sigma, P, S \rangle$ , l'insieme **FIRST** di una stringa  $\alpha$  di variabili e terminali, è definito formalmente come:

$$\text{FIRST}(\alpha) = \{a \mid \alpha \rightarrow^* a\beta\} \cup \{\varepsilon \mid \text{se } \alpha \rightarrow^* \varepsilon\}$$

E' l'insieme dei terminali con cui iniziano le stringhe derivabili da  $\alpha$  nella grammatica  $G$ . **FIRST**( $\alpha$ ) (abb.  $F(\alpha)$ ) soddisfa questa definizione (ricorsiva):

$$1. F(\varepsilon) = \{\varepsilon\}$$

$$F(A) = \bigcup_{A \rightarrow \gamma_i \in P} F(\gamma_i)$$

$$2. F(a\beta) = \{a\}$$

$$3. F(A\beta) = \begin{cases} F(A) & \text{se } A \text{ non è annullabile} \\ (F(A) - \{\varepsilon\}) \cup F(\beta) & \text{se } A \text{ è annullabile} \end{cases}$$

N.B.  $A$  è annullabile se  $A \rightarrow^* \varepsilon$

N.B.  $(A \rightarrow \gamma_1 \mid \gamma_2 \mid \dots \mid \gamma_k)$  è l'insieme delle produzioni di  $A$  in  $G$

# Esempio

$G = \langle \{X, Y, Z\}, \{a, c, d\}, P, Z \rangle$

P:  $Z \rightarrow d \mid XYZ$

$Y \rightarrow c \mid \varepsilon$

$X \rightarrow Y \mid a$

$\text{FIRST}(d) = \{d\}$

$\text{FIRST}(XYZ) = \{a, c, d\}$

Infatti  $Z \rightarrow XYZ \rightarrow aYZ$

$Z \rightarrow XYZ \rightarrow YZ \rightarrow cZ$

$Z \rightarrow XYZ \rightarrow YZ \rightarrow Z \rightarrow d$

$\text{FIRST}\{X\} = \{a, c, \varepsilon\}$

Infatti  $X \rightarrow a$

$X \rightarrow Y \rightarrow c$

$X \rightarrow Y \rightarrow \varepsilon$

# FOLLOW

Data una grammatica  $G = \langle V, \Sigma, P, S \rangle$ , l'insieme **FOLLOW** (insieme dei seguiti) di una variabile  $A$  è l'insieme dei terminali con cui iniziano le stringhe che seguono  $A$  nelle derivazioni della grammatica  $G$  (assumendo  $\$$  in fine stringa). Formalmente:

$$\text{FOLLOW}(A) = \{a \mid S \rightarrow^* \alpha A a \beta\} \cup \{\$ \mid \text{se } S \rightarrow^* \alpha A\}$$

Notare che  $\$$  appartiene sempre al Fw dell'assioma.

**FOLLOW(A)** (abb.  $\text{Fw}(A)$ ) soddisfa la seguente equazione:

$$\begin{aligned} \text{Fw}(A) = & \left[ \bigcup_{B \rightarrow \alpha A \beta \in P} (\text{F}(\beta) - \{\epsilon\}) \right] \cup \left[ \bigcup_{\substack{B \rightarrow \alpha A \beta \in P \text{ tali che} \\ \beta \text{ annullabile e } B \neq A}} \text{Fw}(B) \right] \cup \\ & \cup \{\$ \} \text{ se } A \text{ è lo start symbol di } G \end{aligned}$$



## Esempio

$$Z \rightarrow d \mid XYZ$$
$$Y \rightarrow c \mid \varepsilon$$
$$X \rightarrow Y \mid a$$

$\text{FOLLOW}(Y) = \{a, d, c\}$

Infatti:  $Z \rightarrow XYZ \rightarrow XYXYZ \rightarrow XY\textcolor{red}{a}YZ$

$Z \rightarrow XYZ \rightarrow XY\textcolor{red}{d}$

$Z \rightarrow XYZ \rightarrow YYZ \rightarrow Y\textcolor{red}{c}Z$

$\text{FOLLOW}(X) = \{c, d, a\}$

Infatti:  $Z \rightarrow XYZ \rightarrow X\textcolor{red}{c}Z$

$Z \rightarrow XYZ \rightarrow XYd \rightarrow X\textcolor{red}{d}$

$Z \rightarrow XYZ \rightarrow XYXYZ \rightarrow XXYZ \rightarrow X\textcolor{red}{a}YZ$

$\text{FOLLOW}(Z) = \{\$ \}$  perchè  $Z$  è l'assioma.

# Insiemi guida

Data una grammatica  $G$ , **l'insieme guida** di una produzione della grammatica  $A \rightarrow \alpha$  - **Gui ( $A \rightarrow \alpha$ )** - è l'insieme dei terminali (o  $\varepsilon$  se ci si trova a fine parola) con cui *iniziano* le stringhe generabili a partire dalla produzione stessa :

$$\text{Gui}(A \rightarrow \alpha) = \{a \mid S \rightarrow_{\underline{c}}^* wA\beta \rightarrow w\alpha\beta \rightarrow_{\underline{\text{lm}}} wa\gamma\}$$

L'insieme  $\text{Gui}(A \rightarrow \alpha)$  si può esprimere usando  $F()$  e  $\text{FW}()$ :

$$\text{Gui}(A \rightarrow \alpha) = \begin{cases} F(\alpha) & \text{se } \alpha \text{ non è annullabile} \\ (F(\alpha) - \{\varepsilon\}) \cup \text{FW}(A) & \text{se } \alpha \text{ è annullabile} \end{cases}$$

**Esempio:**

$$\text{Gui}(Z \rightarrow d) = \{d\}$$

$$\text{Gui}(Z \rightarrow XYZ) = \{a, c, d\}$$

$$\text{Gui}(Y \rightarrow c) = \{c\}$$

$$\text{Gui}(Y \rightarrow \varepsilon) = \{a, c, d\}$$

$$\text{Gui}(X \rightarrow Y) = \{a, c, d\}$$

$$\text{Gui}(X \rightarrow a) = \{a\}$$

# Grammatiche LL(1)

Una **grammatica** è **LL(1)** se *per ogni non terminale A e per ogni coppia di produzioni  $A \rightarrow \alpha$  e  $A \rightarrow \beta$ , gli insiemi guida sono disgiunti:*

$$\text{Gui}(A \rightarrow \alpha) \cap \text{Gui}(A \rightarrow \beta) = \Phi$$

## Esempio:

La grammatica  $\langle \{S\}, \{ (, [, <, ), ], > \}, P = \{ S \rightarrow (S) \mid [S] \mid <S> \mid \varepsilon \}, S \rangle$  è LL(1).

$$F(S) = \{ (, [, < \}$$

$$FW(S) = \{ \$, ), ], > \}$$

$$\text{Gui}(S \rightarrow (S)) = \{ ( \}$$

$$\text{Gui}(S \rightarrow [S]) = \{ [ \}$$

$$\text{Gui}(S \rightarrow <S>) = \{ < \}$$

$$\text{Gui}(S \rightarrow \varepsilon) = \{ \$, ), ], > \}$$

## Insiemi GUIDA: esempio di calcolo

$$Z \rightarrow d \mid XYZ$$

$$Y \rightarrow c \mid \epsilon$$

$$X \rightarrow Y \mid a$$

$$F(Z) = \{a, c, d\} \quad F(X) = \{a, c, \epsilon\} \quad F(Y) = \{c, \epsilon\}$$

$$Fw(Z) = \{\$, \}, \quad Fw(X) = \{a, c, d\}, \quad Fw(Y) = \{a, c, d\}$$

$$\text{Gui}(Z \rightarrow d) = F(d) = \{d\}$$

$$\begin{aligned} \text{Gui}(Z \rightarrow XYZ) &= F(XYZ) = (F(X) - \{\epsilon\}) \cup F(YZ) = \\ &= (F(X) - \{\epsilon\}) \cup (F(Y) - \{\epsilon\}) \cup F(Z) = \{a, c, d\} \end{aligned}$$

$$\text{Gui}(Y \rightarrow c) = \{c\}$$

$$\text{Gui}(Y \rightarrow \epsilon) = (F(\epsilon) - \{\epsilon\}) \cup Fw(Y) = \{a, c, d\}$$

$$\text{Gui}(X \rightarrow Y) = \{a, c, d\}$$

$$\text{Gui}(X \rightarrow a) = \{a\}$$

**Data la  
seguente  
Grammatica:**

**Produzione**

**Insieme guida**

- |                             |               |
|-----------------------------|---------------|
| 1. $S \rightarrow PQ$       | $\{a, b, c\}$ |
| 2. $Q \rightarrow \&PQ$     | $\{\&\}$      |
| 3. $Q \rightarrow \epsilon$ | $\{\$\}$      |
| 4. $P \rightarrow aPb$      | $\{a\}$       |
| 5. $P \rightarrow bPa$      | $\{b\}$       |
| 6. $P \rightarrow c$        | $\{c\}$       |

Verificare gli insiemi guida calcolando I FIRST e i FOLLOW usando direttamente le definizioni.

# Calcolo di FIRST(X) (abbreviato F(X))

Un metodo per calcolare gli F(X) per una grammatica  $G = \langle V, \Sigma, P, S \rangle$   
dove  $X \in V \cup \Sigma$ :

1. Si pone  $F(a) = \{a\}$  per ogni  $a \in \Sigma$ .
2. Si pone inizialmente
$$F(A) = \{a \mid A \rightarrow a \alpha \in P\} \cup \{\epsilon \mid \text{se } A \rightarrow \epsilon \in P\}.$$
Altrimenti si inizializza  $F(A) = \{\}$  (insieme vuoto)
3. *per ogni* produzione  $A \rightarrow Y_1 \dots Y_k$ :
  1. si *aggiunge*  $F(Y_1) - \{\epsilon\}$  a  $F(A)$ .
  2. se  $\epsilon \in F(Y_1)$  (tipicamente se  $Y_1 \rightarrow \epsilon \in P$ ) si *aggiunge*  $F(Y_2) - \{\epsilon\}$  a  $F(A)$ .
  3. se  $\epsilon \in F(Y_1)$  e  $\epsilon \in F(Y_2)$  si *aggiunge*  $F(Y_3) - \{\epsilon\}$  a  $F(A)$ .
  4. ....
  5. se  $\epsilon \in F(Y_1), \dots, F(Y_k)$  si *aggiunge*  $\epsilon$  a  $F(A)$ .
4. si ripete il passo 3, fino a che gli insiemi  $F(A)$  non cambiano più

# Esempio

$$G = \langle \{X, Y, Z\}, \{a, c, d\}, P, Z \rangle$$

$$\begin{aligned} P: \quad & Z \rightarrow d \mid XYZ \\ & Y \rightarrow c \mid \varepsilon \\ & X \rightarrow Y \mid a \end{aligned}$$

Valori iniziali:  $F(a) = \{a\}$ ,  $F(c) = \{c\}$ ,  $F(d) = \{d\}$  (non cambiano più)

$$F(Z) = \{d\}, \quad F(Y) = \{\varepsilon, c\}, \quad F(X) = \{a\}$$

Esaminiamo le produzioni nell'ordine in cui sono scritte:

Dopo una *prima* passata:  $F(Z) = \{d, c, a\}$ ,  $F(Y) = \{\varepsilon, c\}$ ,  $F(X) = \{\varepsilon, c, a\}$

Questi sono i valori *definitivi*.

Per esempio  $c \in F(Z)$ . Infatti  $Z \rightarrow XYZ \rightarrow YYZ \rightarrow YZ \rightarrow cZ$

Esempio 2 :  $F(XYZ) = \{c, a\} \cup \{c\} \cup \{d, c, a\} = \{d, c, a\}$

# Calcolo dei Follow(A) (abbreviato Fw(A))

Sia data una grammatica  $G = \langle V, \Sigma, P, S \rangle$ . Si eseguono i seguenti passi

1. Per ogni  $A \in V$  Si calcolano  $F(A)$ . Si suppone inizialmente  $Fw(S) = \{\$ \}$  e  $Fw(A)$  vuoto per ogni altra  $A \in V$ .
2. per ogni produzione  $A \rightarrow \alpha B \beta \in P$ , e per ogni  $\beta$  si *aggiunge*  $F(\beta) - \{\epsilon\}$  a  $Fw(B)$
3. *per ogni* produzione  $A \rightarrow a B \beta \in P$  tale che  $\epsilon \in F(\beta)$  (ovvero  $\beta \in V^*$  è annullabile) si *aggiunge*  $Fw(A)$  a  $Fw(B)$  ;
4. si ripete il passo 3. fino a che gli insiemi non si cambiano più.

**Note:** conviene esaminare le produzioni in un ordine fisso.



## Esempio

$Z \rightarrow d \mid XYZ$

$Y \rightarrow c \mid \varepsilon$

$X \rightarrow Y \mid a$

Ricordiamo che  $F(Z) = \{d, c, a\}$ ,  $F(Y) = \{\varepsilon, c\}$ ,  $F(X) = \{\varepsilon, c, a\}$

Valori *iniziali*:  $Fw(Z) = \{\$ \}$ ,  $Fw(Y) = \{ \}$ ,  $Fw(X) = \{ \}$

Dopo il *passo 2.*:  $Fw(Z) = \{\$ \}$ ,  $Fw(Y) = \{d, c, a\}$ ,  $Fw(X) = \{d, a, c\}$ .

Non ci sono le condizioni per eseguire il *passo 3.* quindi si salta.

Questi sono i valori definitivi.

Per esempio  $a \in Fw(Y)$ .

Infatti  $Z \rightarrow X \textcolor{brown}{Y} Z \rightarrow X \textcolor{brown}{Y} X Y Z \rightarrow X \textcolor{brown}{Y} a Y Z$